
악성코드 탐지, 암호화 및 패키징 프로젝트

데이터셋 수집 보고서

목 차

1. 데이터 수집 정책
2. 선정된 데이터
3. 선정되지 않은 데이터
4. 결론

```

graph TD
    Start1[ ] --> Check1{블록체스트 확인}
    Check1 -- YES --> End1[저장된 구조 출력]
    Check1 -- NO --> Step1[만지 API 동작]
    Step1 --> Check2{헤더필드 유무}
    Check2 -- YES --> Step2[파일 구조 출력]
    Step2 --> End2[/블록체스트 정보 추가/]
    Check2 -- NO --> End3[/파일 다운로드/]
  
```

블랙리스트를 만들기 위해선 사전 정의된 바이러스 정보가 있는 데이터셋을 사용해야 합니다. 가장 좋은 방안으로는 Virus Total 에 정의되어 있는 정보를 가져오는 것이지만 서비스에서 따로 제공해주는 데이터가 없었습니다. 그래서 저희는 다른 사이트를 서치하여 데이터셋을 수집하기로 했습니다.

```

graph LR
    A[데이터셋 전체] --> B[데이터가 100기 이상인가(총합 1000기 이상도 데이터 필요)]
    A --> C[엑셀코드 파일을 모아둔 데이터셋인가]
    A --> D[exe 파일에 대한 데이터 셋인가]
    B --> E[데이터에서 해커가 있나]
    E --> F[해커 없이도 필요한 정보가 있는가]
    E --> G[관계 파일에 대한 해커 접근인가]
    E --> H[사용자 코드 영역 색인에 대한 해커 접근인가]
    G --> I[해커 없이 Sha-256으로 되어있나]
    G --> J[해커 없이 MD5로 구성되어 있나]
    H --> I
    H --> J
    C --> K[약정코드 구조를 정적으로 분석해서 사용자 코드 영역만 제시하]
    K --> L[구조 분석하고 제시한 모듈 개발]
    D --> M[엑셀코드 파일을 모아둔 데이터셋인가]
  
```

The flowchart illustrates a security audit process for a database system. It starts with '데이터셋 전체' (All dataset), which branches into three main paths: '데이터가 100기 이상인가(총합 1000기 이상도 데이터 필요)' (Is the data 100 or more units? (Total 1000 or more units also need data)), '엑셀코드 파일을 모아둔 데이터셋인가' (Is the dataset containing Excel code files?), and 'exe 파일에 대한 데이터 셋인가' (Is the dataset for exe files?). The first path leads to '데이터에서 해커가 있나' (Are there hackers in the data?), which then branches into '해커 없이도 필요한 정보가 있는가' (Is there necessary information even without a hacker?), '관계 파일에 대한 해커 접근인가' (Is there a hacker's access to the relationship file?), and '사용자 코드 영역 색인에 대한 해커 접근인가' (Is there a hacker's access to the user code area coloring?). The second path leads to '약정코드 구조를 정적으로 분석해서 사용자 코드 영역만 제시하' (Analyze the agreement code structure statically and only present the user code area), which then leads to '구조 분석하고 제시한 모듈 개발' (Analyze the structure and develop the presented module). The third path leads to '엑셀코드 파일을 모아둔 데이터셋인가' (Is the dataset containing Excel code files?). The '관계 파일에 대한 해커 접근인가' and '사용자 코드 영역 색인에 대한 해커 접근인가' paths both lead to two possible outcomes: '해커 없이 Sha-256으로 되어있나' (Is it without a hacker and Sha-256?) and '해커 없이 MD5로 구성되어 있나' (Is it without a hacker and composed of MD5?).

1. 데이터가 100 개 이상인가?
2. 데이터셋에 해시 값이 포함되어 있나?

- 3. 전체 파일에 대한 해시 값인가?
- 4. MD5 해시가 있는가?

저희가 만들 블랙 리스트는 서비스의 시간 단축이 목적인 데이터 셋입니다. 따라서 사전에 정의된 데이터들이 많으면 좋습니다. 따라서 위에 4 개의 정책을 중점으로 데이터셋을 수집했습니다.

2. 선정된 데이터

최종적으로 선정된 데이터셋은 Malware bazaar abuse 에서 가져온 csv file 입니다. 이 파일은 2020 년 2 월 13 일부터 2024 년 8 월 29 일까지 이 사이트에 보고된 바이러스 파일들에 대한 정보가 포함되어 있습니다.

데이터셋 출처 : <https://bazaar.abuse.ch/export/>

포함된 정보

이름	설명
first_seen_ufc	바이러스가 처음 보고된 시간
sha256_hash	파일의 SHA-256 해시 값
md5_hash	파일의 md5 해시 값
sha1_hash	파일의 SHA-1 해시 값
reporter	바이러스를 보고한 사람
file_name	바이러스 파일의 이름
file_type_guess	바이러스 파일의 형식(추정값)
mime_type	바이러스 파일의 MIME 유형
signature	바이러스의 정의된 이름(ex. Loki)
clamav	Clamav 동작 후 나온 값(ex. RedLineStealer)
vtpercent	Virustotal 검사 점수
imphash	PE 파일의 import table 해시 값
ssdeep	파일 간 유사성을 비교하기 위한 해시 값
tlsh	TLSH 해시 값. 파일의 유사성을 비교하기 위한 해시

이 데이터셋에는 이러한 정보가 담긴 데이터가 약 80 만개가량 있습니다. 해당 데이터셋을 가공하여 블랙리스트의 정보를 만드는데 적합하다고 판단했습니다. 최종적으로 블랙리스트에 적용되어야 할 정보는 Virustotal 사이트를 통해서 나온 detail 과 behavior 섹션의 값이므로 Virustotal API 를 적용시켜 가공할 수 있는 데이터셋으로 MD5 hash 를 선정했습니다. 이 데이터셋을 API module 을 통해 가공하여 블랙리스트를 정의할 것입니다.

3. 선정되지 않은 데이터

루트킷 및 백도어 악성코드 데이터셋

<https://www.bigdata-telecom.kr/invoke/SOKBP2603/?goodsCode=KIS0000035>

선정되지 않은 이유 : 데이터셋 수집 정책에 따라서 데이터셋을 분석한 결과 블랙리스트를 구축하기에 필요한 필수 정보들(해시 값 등)이 부족했습니다.

Microsoft Malware Classification Challenge (BIG 2015)

<https://www.kaggle.com/c/malware-classification>

선정되지 않은 이유 : 데이터셋의 데이터가 많았지만 블랙리스트를 구축하기에 필요한 필수 정보들(해시 값, 파일 정보 등)이 부족했습니다.

한국인터넷진흥원 - 정상 및 악성코드 데이터셋

<https://www.gimi9.com/dataset/bdp-kt-co-kr-dataset-1367055>

선정되지 않은 이유 : 해시 값은 있었지만 정상 파일도 포함되어 있어 블랙리스트를 구성하는데 분류 과정이 늘어나기 때문에 선정에서 제외했습니다.

대용량 정상/악성파일 II(test set)

<https://www.ksecurity.or.kr/kisis/subIndex/375.do>

선정되지 않은 이유 : 데이터셋의 데이터가 많았지만 블랙리스트를 구축하기에 필요한 필수 정보들(해시 값, 파일 정보 등)이 부족했습니다.

대용량 정상, 악성파일 5

<https://www.ksecurity.or.kr/kisis/subIndex/493.do>

선정되지 않은 이유 : 데이터셋의 데이터가 많았지만 블랙리스트를 구축하기에 필요한 필수 정보들(해시 값, 파일 정보 등)이 부족했습니다.

SoReL-20M

<https://github.com/sophos/SOREL-20M>

선정되지 않은 이유 : Amazon S3 를 통해 구성해야 하는 데이터셋으로 NCP 를 사용하는 것이 좋지 때문에 선정에서 제외됐습니다. 또한 데이터셋의 용량이 8TB 이기 때문에 저희에게 할당된 서비스 요금만으로는 처리가 힘들 것 같아 제외됐습니다.

VirusShare info

<https://virusshare.com/>

선정되지 않은 이유 : 수집하는 데이터의 문제는 없었으나 홈페이지 이용 및 다운로드의 어려움 때문에 데이터셋을 구할 수 없었습니다.

4. 결론

블랙리스트와 Virus total API 를 돌려서 나온 정보가 불균형을 이루면 안되기 때문에 Virustotal API 로 데이터를 가공해야 합니다. 따라서 수집해야 할 데이터셋에는 해시 값이 필수로 포함되어 있어야합니다. 해당 해시 값으로 Virustotal API module 을 작동시켜 나온 데이터를 데이터베이스에 저장하여 블랙리스트 데이터베이스를 구성해야 합니다.

저희는 최종적으로 Malware Bazzar abuse 의 악성코드 데이터셋을 선정했고 해당 데이터는 약 80 만개의 데이터를 포함하고 있습니다. 데이터셋에는 md5, sha-256 등의 중요한 해시정보가 포함되어 있고 저희는 md5 hash 값을 이용해 데이터를 재가공 할 예정입니다.

악성코드의 분석 데이터는 정형화 되어있지 않는 경우가 많기 때문에 데이터베이스 선정에 있어서 No-SQL 방식의 데이터베이스를 선정해야 했습니다. 저희는 BSON 형식으로 데이터를 저장하는 MongoDB 를 선정했고 해당 DB 에 블랙리스트를 구축할 것입니다.